LOG6951A

TP1

Julien SEGONNE (2409827) - Michelle SEPKAP (1929767)

Mars 2026

POLYTECHNIQUE MONTRÉAL

Table des matières

1 Introduction **3**

2 Architecture **3**

3 Choix technologiques **4**

4 Stratégie de chunking **4**

5 Patron de prompt appliqué **4**

6 Comparaison des stratégies de retrieval **5**

7 Techniques d'optimisation de requête **6**

8 Utilisation de l'IA générative **7**

9 Conclusion **7**

10 Annexes **8**

10.1 Similarité cosinus vs MMR 8

10.2 Tests du Multi-query (avec RRF) 14

Table des figures

1 Diagramme du pipeline RAG 3

1 Introduction

Avec l'avènement de l'intelligence artificielle et des modèles de langage, les pipelines RAG permettent d'en tirer profit en ayant accès à des connaissances externes actualisées tout en évitant les coûts d'entraînement.
Nous présenterons la conception et des résultats d'implétention de ResearchPal, un assistant de recherche personnel basé sur une architecture RAG (Retrieval-Augmented Generation). ResearchPal est un outil permettant à un utilisateur de soumettre des documents et d'y poser des questions en langage naturel. L'objectif du système est de récupérer les passages pertinents et générer des réponses fondées sur les sources ingérées, avec citations. Les documents ingérés peuvent être de différentes natures : documents PDF, documents texte, documents markdown et pages web.
Les tests ont été réalisés sur un corpus de 5 documents couvrant des domaines différents :

— publication-code-source-ouvert.md : Guide pour la publication du code source libre du gouvernement du Canada ;

— CAI_GU_EFVP.pdf : Guide d'accompagnement à la réalisation d'une évaluation des facteurs relatifs à la vie privée ;

— lprp.pdf : Loi sur la protection des renseignements personnels dans le secteur privé ;

— https://fr.wikipedia.org/wiki/Le_Seigneur_des_anneaux : Page wikipedia sur l'oeuvre "Le Seigneur des Anneaux" ;

— https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents : Page web sur la définition d'un contexte efficace pour les agents IA.

2 Architecture

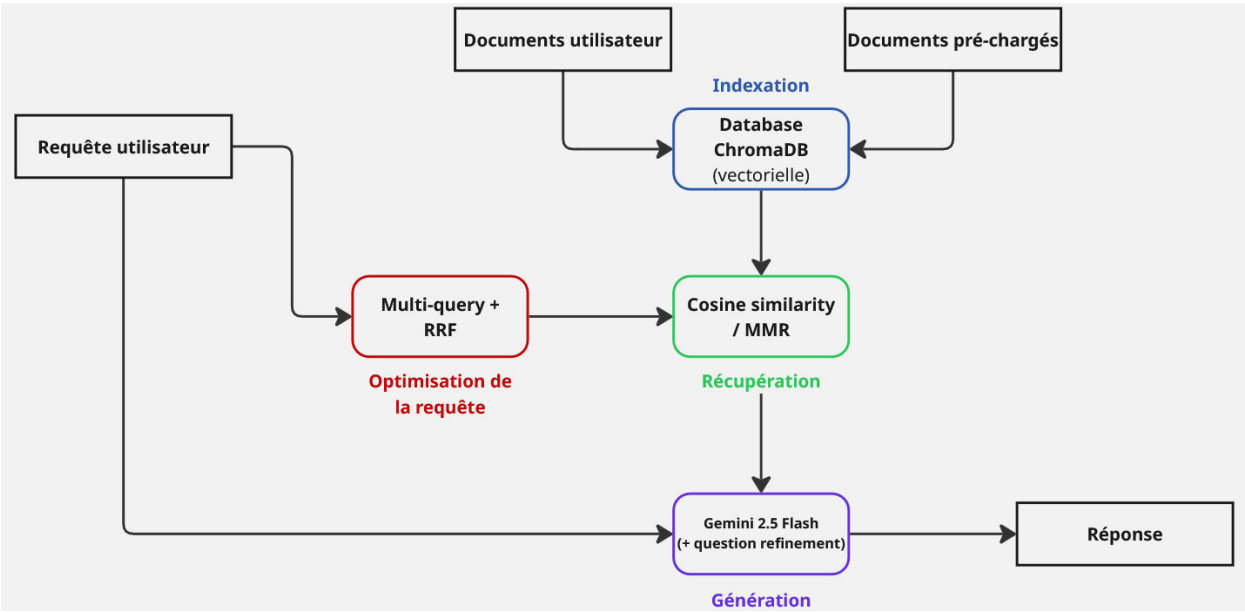

FIGURE 1 – Diagramme du pipeline RAG

3 Choix technologiques

Le LLM que nous avons choisi pour générer les réponses dans notre outil est *Gemini 2.5 Flash* via l'API de Google. Ce choix a été motivé par ces trois raisons :

— La génération des réponses est rapide.

— L'API est facile à prendre en main.

— Passer par une API permet de ne pas avoir à installer un modèle en local, qui pourrait ne pas être supporté par toutes les machines.

Le modèle d'embeddings choisi est le sentence transformers *Qwen/Qwen3-Embedding-0.6B* car il est facile d'accès (disponible sur HuggingFace) et d'usage (via les fonctions de langchain propres à HuggingFace. Aussi, comparé à des modèles plus petits ou plus rapides comme all-MiniLM-L6-v2, il permet d'avoir une plus grande fenêtre de contexte et performe mieux dans des pipelines RAG avec des textes un peu plus longs et des langues variées. Il a également une bonne réputation et de bons résultats dans le leaderboard mteb.

4 Stratégie de chunking

Le *recursive chunking* est appliqué lors de l'indexation pour les documents pdf, txt et les pages web. Il semble être le bon compromis entre un chunking fixe (perd le sens des paragraphes et des phrases coupées, il pourrait y avoir deux paragraphes n'ayant pas de lien dans un chunk) et le chunking sémantique qui nécessiterait les embeddings des phrases pour les regrouper et par conséquent plus de temps de traitement. Le chunking récursif permet de séparer par paragraphe quand c'est possible, sinon par retour ligne, phrase, etc. Cela conserve une grande partie du contexte par chunk. Pour les documents markdown (.md) spécifiquement, le chunking est fait selon la structure du document, par rapport aux headers de niveau 1, 2 et 3 afin de capturer le sens selon cette structure et d'avoir une meilleure précision.
La taille des chunks est fixée à *500 tokens* pour pouvoir englober des paragraphes (si un paragraphe est entier dans ces 500 tokens, il est sélectionné et la taille du chunk sera donc égale à la taille du paragraphe). Si ce n'est pas le cas, on obtient donc un grand chunk avec suffisament de contenu pour avoir une bonne représentation sémantique de celui-ci. La taille du chevauchement est fixée à *50 tokens* pour avoir quelques phrases en début et fin de chunk qui permettent de faire le lien avec les idées précédentes et suivantes. Du point de vue des embeddings, cela permet de ne pas avoir une passage "catapulté" sans contexte, sans lien avec le texte l'entourant.

5 Patron de prompt appliqué

Le patron employé dans le system prompt est un *question refinement*. Il demande au LLM de reformuler chaque question en l'enrichissant avec plus de vocabulaires et de verbes spécifiques avant d'y répondre. Ceci pousse le LLM à améliorer sa propre réponse en apportant plus d'informations

et de termes techniques propres à la requête, elle sera donc plus complète et plus riche. Cela a aussi pour effet d'apporter plus d'informations par rapport à la requête initiale (si l'on donnait une requête pauvre, on obtenait une réponse pauvre).

Remarque : Une amélioration du RAG pourrait utiliser cette technique en deux temps : reformuler la requête de l'utilisateur puis utiliser cette requête plus riche (avec plus de vocabulaires) pour faire la recherche de documents et argumenter sa réponse. La multi-query est une technique semblable (reformulations de la query + recherche sur toutes les reformulations) que nous exploitons dans notre outil.

6 Comparaison des stratégies de retrieval

Les résultats des 5 requêtes sont présentés en annexe *Similarité cosinus vs MMR*. Nous avons choisi les paramètres suivants : $k = 5$ et $\lambda = 0.5$ (mélange équitable entre diversité et pertinence pour le MMR).

Qui sont les personnages principaux du Seigneur des Anneaux ?

Pour cette question, on voit clairement une différence entre MMR et similarité cosinus. La similarité cosinus propose des réponses qui contiennent seulement les termes "Seigneur des anneaux" et n'arrive pas à prendre de recul pour proposer des passages avec des personnages. En revanche le MMR propose des réponses avec des noms propres (Hobbit, Sam, Sauron...) et jamais les mêmes, même si ce n'est pas tout le temps des personnages (Christina Scull par exemple). Nous pouvons tout de même remarquer que sa première réponse est le lien contenant "Seigneur des anneaux" mais une fois cette proposition faite, il ne revient plus jamais sur une similaire.

Qui est Tolkien ?

Ici, la même observation est faite : la similarité cosinus propose des passages contenant "Tolkien" systématiquement, le MMR propose lui des noms propres (dont Tolkien) mais dans ce cas précis ça n'est pas pertinent car on cherche le plus d'informations sur une seule personne.

Quel âge avait J R R Tolkien au moment de l'écriture ?

Pour cette question, la réponse n'est peut être pas écrite explicitement dans les données. Le premier passage sélectionné par les deux modèles comprend "Tolkien", une date, le mot "âge" et 15 ans. On comprend bien pourquoi ce passage a été sélectionné, du point de vue d'une machine il semble proche de la requête. Globalement, la similarité cosinus propose des passages avec le nom et des dates ou des nombres. Le MMR propose en 5ème position la liste des oeuvres avec leur date de parution, ce comportement est très intéressant car couplé avec des informations sur Tolkien, il pourrait permettreà un LLM de remonter à son âge.

Peut-on considérer le Seigneur des Anneaux comme une œuvre de fantasy épique ?

Encore une fois, la similarité cosinus reste assez "collée" à la requête et suggère des passages contenant le titre de l'oeuvre. Le MMR, lui, montre bien sa diversité avec des passages ayant un champ lexical de la fantasy ("mythe", "légende", "monde imaginaire"...), en éliminant les premières réponses trop proches de la requête, des passages intéressants sont proposés.

Qui sont les principaux contributeurs à l'univers du Seigneur des Anneaux ?

Cette question est assez difficile car elle demande du recul et une appréciation sur des informations. La similarité cosinus observe le comportement habituel, le MMR a une tentative intéressante : il propose un passage avec "Paradox Development Studio", il introduit donc un nouvel acteur qui n'est pas un personnage ni l'auteur.

Discussion sur les paramètres

— $k = 5$ est une manière d'avoir quelques passages à analyser sans être surchargé. Nous obtenons déjà des résultats intéressants. Un plus faible k donnerait trop peu d'information (pour nous comme pour un LLM), un plus grand k est envisageable mais il faut bien veiller à ne pas noyer le LLM dans trop d'informations. Un grand k permet d'obtenir une grande diversité avec le MMR mais trop de redondance avec la similarité cosinus.

— $\lambda = 0.5$ permet d'obtenir assez rapidement des résultats divers. Nous venons de voir que ce λ (ou un plus élevé) n'est pas adapté pour les types de question ressemblant à la deuxième qui nécessite beaucoup d'informations sur un même type d'objet (pour enrichir la réponse). Un plus faible λ pourrait aider pour ce type de question mais on perdrait en diversité. Si l'on augment le k en même temps cela pourrait permettre d'allier quantité de données et diversité.

7 Techniques d'optimisation de requête

Après obtention de la requête de l'utilisateur, une optimisation en est faite avant d'être passée au modèle pour la génération de réponse. La stratégie choisie est une multi-query puis fusion des résultats par Reciprocal Rank Fusion. Le modèle de langage choisi génère n (3 par défaut) variantes de la requête initiale, formulée différemment, en gardant le même sens mais avec des angles différents. Une récupération des documents (retrieval) est faite sur chacune des variantes et les résultats sont combinés, dédupliqués et classés avec Reciprocal Rank Fusion.
Le corpus étant varié avec des sujets complexes (droit et sécurité, guides, context engineering, littérature), les questions peuvent elles aussi être complexes et cela nécessite de prendre en compte différentes perspectives pour en cerner tous les contours ou encore de les reformuler pour faire appel aux bonnes sources. Cette méthode intéressante permet de compléter la requête initiale et d'améliorer la recherche des documents afin de fournir au modèle un contexte plus pertinent pour la réponse finale. Cela permet aussi de dédupliquer les sources utilisées par le modèle, en cas

d'ingestion répétée du même document, enrichissant ainsi les sources pour de meilleurs résultats. Par ailleurs, prendre des angles différents pourraient permettre de fournir des réponses qui lient des concepts dans plus d'un document.
Les résultats sont disponibles dans la deuxième annexe *Tests du Multi-query (avec RRF)*.

Analyse des tests

Pour la première question *Que faut-il pour publier du code source ouvert du GC ?*, on remarque que la multi-query permet d'obtenir des requêtes avec plus de vocabulaire pertinent (diffusion, logiciels libres, public...), il en résulte une réponse plus complète / diverse avec une section "Recommandations supplémentaires" qui ajoute de l'information en lien avec la query initiale (mais avec un vocabulaire différent). Toutefois, la réponse est un peu moins détaillée sur la partie "Procédures obligatoires".
Pour la question *Est-ce que publier ce code constitue une infraction à la loi sur la protection des renseignements personnels ?*, encore une fois la multi-query développe plus de vocabulaires, et elle permet finalement de donner quelques exemples d'infraction. La réponse est tout de même similaire à la requête sans multi-query dans le fond (impossibilité de répondre à la question).
La question *Qu'est-ce qu'un renseignement personnel sensible et que faut-il faire en cas de collecte de renseignements personnels sensibles ?* illustre bien l'utilité du multi-query : sa réponse donne une information importante supplémentaire ("éviter la collecte excessive de données") qu'il a pu trouver grâche aux reformulations.
Enfin, la question suivante *Et l'EFVP ?* illustre encore plus ce phénomène : la version multi-query est beaucoup plus complète et exhaustive, et permet de manquer le moins possible d'information, en particulier dans ce type de contexte sensible.
Les autres questions/réponses en annexe démontrent aussi les points discutés précédemment et illustrent bien les différences des deux méthodes.

8 Utilisation de l'IA générative

Pour réaliser ce projet, nous avons utilisé :

- Gemini 3 sur le web pour faire des recherches (notamment sur langchain), comprendre les algorithmes et générer quelques fonctions au cas par cas (le MMR par exemple),
- GPT-5 mini et Claude Opus 4.6 par le biais de github copilot pour adapter des fichiers en entier (changement de nom de variable par exemple), pour générer des fonctions nécessitant l'architecture de l'outil ou d'autres fichiers en contexte et pour aider à rédiger le readme.

9 Conclusion

Les résultats produits par l'assistant conçu sont intéressants, mais pourraient être meilleurs. En effet, on constate certaines limitations :

— La vitesse d'ingestion et de réponse : le temps d'attente peut être long dans certains cas, un moyen de le réduire serait d'avoir un modèle plus performant, mais aussi de mettre en place des stratégies de cache ;

— Avec un système de mémoire plus développé (utiliser un buffer ou un résumé), l'outil pourrait fournir des réponses plus personnalisées et faire plus de liens avec les messages précédents ;

— L'ordre des sources n'est pas toujours donné selon la pertinence, un reranking sur les résultats du retrieval pourrait être exploré pour améliorer la qualité des réponses ;

— Pour avoir des réponses un peu moins générique dans une base de données assez diverse comme dans notre cas, nous pourrions aussi mettre en place un système de routing menant à différents system prompt selon la requête (bien citer les sources pour de la législation, avoir une réponse complète et faire des liens entre histoires/personnages pour la littérature, respecter certaines règles s'il faut générer du code...).

10 Annexes

10.1 Similarité cosinus vs MMR

Sources : *Le Seigneur des anneaux Tome 1*, *Le Seigneur des anneaux Tome 2*, page Wikipédia "Le Seigneur des anneaux (série de films)", page Wikipédia "Le Seigneur des anneaux" et page Wikipédia "J. R. R. Tolkien".

Paramètres : $k = 5$ et $\lambda = 0.5$

Qui sont les personnages principaux du Seigneur des Anneaux ?

Position de la réponse	**Similarité Cosinus**	**MMR**
1	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?title=Le_Seigneur_des _anneaux&oldid=234145930».	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?title=Le_Seigneur_des _anneaux&oldid=234145930».
2	Le seigneur des anneaux PREMIERE PARTIE Page 35 sur 211 La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ	Les Hobbits montèrent sur une pente douce, passant devant quelques maisons séparées, et ils s'arrêtèrent à la porte de l'auberge. Les maisons leur paraissaient grandes et étranges. Sam leva des yeux étonnés sur les trois étages et les nombreuses fenêtres de l'auberge, et il sentit son cœur se serrer. [...]
3	— Avant-propos de la seconde édition du Seigneur des anneaux	La quête des personnages consiste à trouver le moyen de détruire l'Anneau unique, puissant objet magique forgé par Sauron et qui contient la plus grande partie de ses pouvoirs maléfiques. L'Anneau rend invisible la personne qui le porte, mais l'expose aussi à une tentation constante qui risque de la faire passer sous l'influence de Sauron. Comme le soulignent Wayne G. Hammond et Christina Scull [...]
4	Le Seigneur des anneaux Est une de ces choses : Si vous l'aimez c'est bien Sinon vous criez bah !	encore dans l'avenir. Si nous retournons maintenant, alors l'Anneau doit demeurer ici. nous ne serons pas en état de repartir. Et puis, tôt ou tard, Fondcombe sera assiégée et, après un temps aussi bref qu'affreux, elle sera détruite. Les Esprits Servants de l'Anneau sont des ennemis mort els, mais ce ne sont que des ombres du pouvoir et de la terreur qu'ils posséderaient si l'Anneau Souverain était de nouveau au doigt de leur maître.
5	alors la rédaction du Seigneur des anneaux, sans se douter qu'il lui faudra plus de dix ans pour l'achever[47].	trop peu les ruses d'Arachne. Il y avait maintes issues à son antre.

Qui est Tolkien ?

Position de la réponse	**Similarité Cosinus**	**MMR**
1	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?titleJ̄._R._R._Tolkien &oldid2̄34074427».	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?titleJ̄._R._R._Tolkien &oldid2̄34074427».
2	en 1977 par son fils et exécuteur littéraire Christopher Tolkien, assisté de Guy Gavriel Kay. Au cours des décennies qui suivent, celui-ci publie régulièrement des textes inédits de son père.	[...] - Et Peut-être en était-il ainsi, dit Frodo. Dans ce pays-là, il se peut que nous fussions en un temps qui ailleurs était depuis longtemps passé. C'est seulement quand le Cours d'Argent nous eut ramenés à l'Anduin, je crois, que nous sommes revenus au temps qui s'écoule par les terres de mortels vers la Gr ande Mer. Et je ne me
3	athée, au christianisme, bien qu'il choisisse l'anglicanisme, au grand désarroi de Tolkien[63].	- Mais qu'en est-il de ce Frodo qui vit avec lui ? Demanda le Vieux Chénier de Lè zeau. Il s'appelle Baggins, mais il est plus qu'à moitié un Brandebouc, à ce qu'on d it. Je ne comprends pas pourquoi un Baggins de Hobbitebourg irait chercher femme là-bas dans le Pays de Bouc, où les gens sont si bizarres. - Et il n'y a rien d'étonnant à ce qu'ils le soient, intervint Papa Bipied (voisin immédiat de l'Ancien), vu qu'ils
4	En France, selon Guido Semprini, la réception de l'œuvre de Tolkien a donné lieu durant les premières décennies à des malentendus explicables par le caractère tardif de la traduction du Seigneur des Anneaux qui fait que Tolkien, au lieu d« 'être rangé parmi les écrivains de l'entre-deux-guerres, fut donc appréhendé comme un écrivain des années 70 par la critique française » [...]	attardent encore. Mais, même ainsi, ce fut le Gondor qui amena sa propre décadence, tombant petit à petit dans le gâtisme et croyant au sommeil de l'Ennemi, qui n'était que banni et non détruit.
5	d'autorisation de la part de Tolkien et sans lui offrir aucune compensation. Tolkien le fait savoir clairement aux fans américains qui lui écrivent et passe l'été 1965 à réviser le texte du livre, corrigeant les fautes, adaptant quelques éléments de la mythologie [...]	Madison, sort la même année et raconte l'histoire des parents d'Aragorn[102].

Quel âge avait J R R Tolkien au moment de l'écriture ?

Position de la réponse	Similarité Cosinus	MMR
1	Tolkien aborde sa conception personnelle des langues construites dans son essai Un vice secret, issu d'une conférence donnée en 1931[180]. La composition d'une langue, pour lui, relève d'un désir esthétique et euphonique, participant d'une satisfaction intellectuelle et d'une « symphonie intime ». Il dit avoir commencé à inventer ses propres langues vers l'âge de 15 ans, et son métier de philologue n'est qu'un des reflets de sa passion profonde pour les langues. S'il considère avant tout	Tolkien aborde sa conception personnelle des langues construites dans son essai Un vice secret, issu d'une conférence donnée en 1931[180]. La composition d'une langue, pour lui, relève d'un désir esthétique et euphonique, participant d'une satisfaction intellectuelle et d'une « symphonie intime ». Il dit avoir commencé à inventer ses propres langues vers l'âge de 15 ans, et son métier de philologue n'est qu'un des reflets de sa passion profonde pour les langues. S'il considère avant tout
2	en 1977 par son fils et exécuteur littéraire Christopher Tolkien, assisté de Guy Gavriel Kay. Au cours des décennies qui suivent, celui-ci publie régulièrement des textes inédits de son père.	des fêtes pour célébrer les dates repères, comme pour célébrer le 666e jour de travail[34]. Leur dernier enregistrement a été un de la Porte Noire, pour le troisième film, en novembre 2003[27].
3	ont traité du lien entre science et l'oeuvre de Tolkien[154],[155],[156],[157].	assez de pain pour le temps qu'il resterait frais. Gollum ne mangea rien.
4	Ce document provient de « https ://fr.wikipedia.org/w/index.php ?title=J._R._R._Tolkien& oldid=234074427 ».	et son éviction du conseil d'administration du Tolkien Estate[58].
5	Pour l'opposition de Tolkien à l'emploi de ce terme, voir les lettres, nos 149 (à Rayner Unwin, du 9 septembre 1954) et 165 (à la Houghton Mifflin Company, juin 1955). Il l'utilise dans la lettre, no 227 à E. C. Ossen Drijver (5 janvier 1961), entre autres.	Le Hobbit (2012-2014) : Un voyage inattendu (2012) La Désolation de Smaug (2013) La Bataille des Cinq Armées (2014) Les Anneaux de pouvoir (2022-) La Guerre des Rohirrim (2024) À la radio 1955 1979 1981 Fanfilms The Hunt for Gollum (2009) Born of Hope (2009) Voir aussi Traductions Jeux adaptés The History of The Lord of the Rings Le Hobbit Musée Greisinger v · mL'œuvre de J. R. R. Tolkien Œuvres de fiction

Qui sont les principaux contributeurs à l'univers du Seigneur des Anneaux ?

Position de la réponse	Similarité Cosinus	MMR
1	Le seigneur des anneaux PREMIERE PARTIE Page 35 sur 211 La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ	Le seigneur des anneaux PREMIERE PARTIE Page 35 sur 211 La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ
2	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?title=Le_Seigneur_des _anneaux&oldid=234145930».	des Ents-femmes quand nous pensions à elles. Nous croyons que nous les rencontrerons peut-être de nouveau dans un temps à venir et que nous pourrons alors trouver quelque part un pays où vivre ensemble avec une satisfaction réciproque. Mais il est présagé que ce ne sera que lorsque nous aurons les uns et les autres perdu tout ce que nous avons à présent. Et il se pourrait bien que ce temps approche enfin. Car si Sauron détruisit
3	— Avant-propos de la seconde édition du Seigneur des anneaux	[...] qu'ils se virent dans l'impossibilité de regrimper pour en sortir ni d'un côté ni de l'autre sans abandonner leurs poneys et leur bagage. Tout ce qu'ils purent faire fut de suivre le repli da ns sa descente. Le sol se fit mou et, en certains endroits, marécageux, des sources apparurent sur l es talus, et ils se trouvèrent bientôt suivre un ruisseau qui gazouillait dans
4	Le seigneur des anneaux PREMIERE PARTIE Page 34 sur 211 La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ «Mais je ne pense pas qu'il vous soit nécessaire de par tir seul. Pas si vous connaissez quelqu'un de confiance, qui serait disposé à aller à votre côté et que vous seriez disposé à entraîner dans des périls inconnus. [...]	jeu développé par Paradox Development Studio en 2012, reconstitue plutôt la succession des rois au fil du temps et les jeux d'alliances entre peuples et royaumes[118].
5	Le Troisième Âge du Soleil et Le Seigneur des anneaux s'achèvent.	anniversaire. Déagol aurait dû lui faire cadeau de l'Anneau. Celui ci avait manifestement fait son apparition pour être un cadeau. C'était son cadeau d'anniversaire, etc. [...]

Peut-on considérer le Seigneur des Anneaux comme une œuvre de fantasy épique ?

Position de la réponse	**Similarité Cosinus**	**MMR**
1	— Avant-propos de la seconde édition du Seigneur des anneaux	— Avant-propos de la seconde édition du Seigneur des anneaux
2	Le seigneur des anneaux PREMIERE PARTIE Page 35 sur 211 La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ	Tolkien connaît bien le mythe arthurien, notamment le poème moyen anglais [...]. Toutefois, il n'apprécie pas ce corps de légendes outre mesure : « trop extravagant, fantastique, incohérent, répétitif » à son goût pour pouvoir constituer une véritable « mythologie de l'Angleterre[115] ». Cela n'empêche pas des motifs et échos arthuriens d'apparaître de manière diffuse dans Le Seigneur des anneaux, le plus évident
3	Le seigneur des anneaux [...] Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ Un Anneau pour les gouverner tous. Un Anneau pour les trouver. Un Anneau pour les amener tous et dans les ténèbres les lier. «Ce ne sont que deux vers d'un poème depuis longtemps connu dans la tradition elfique Trois Anneaux pour les Rois Elfes sous le ciel, Sept pour les Seigneurs Nains dans leurs demeures de pierre, Neuf pour les Hommes Mortels destinés au	avec Bilbo et moi-même, et avec notre anneau. - Ça a tout à faire avec cela, dit Gandalf. Vous ne c onnaissez pas encore le véritable péril, mais vous le connaîtrez. Je n'en étais pas sû r moi-même, la dernière fois que je suis ve nu ici, mais le moment est venu de parler. Donnez-moi l'anneau un moment. Frodo le tira de la poche de sa culotte, où il était accr oché à une chaînette suspendue à sa ceinture. Il le
4	Ce document provient de «https ://fr.wikipedia.org/w/ index.php ?title=Le_Seigneur_des _anneaux&oldid=234145930».	Le Seigneur des anneaux est bien entendu une œuvre fondamentalement religieuse et catholique ; [...] C'est pour cette raison que je n'ai pratiquement pas ajouté, ou que j'ai supprimé les références à ce qui s'approcherait d'une « religion », à des cultes et à des coutumes, dans ce monde imaginaire. Car l'élément religieux est absorbé dans l'histoire et dans le symbolisme[119]. »
5	Le seigneur des anneaux [...] La communauté de l'anneau Livre I CHAPITRE DEUX L'OMBRE DU PASSÉ [...] cette arrivée de Bilbo juste à ce moment et la façon dont il a posé la main dessus, à l'aveuglette, dans le noir.	[...] Les Ents-femmes leur ordonnaient de pousser selon leurs vœux et de porter des feuilles et des fruits à leur goût, car les Ents-femmes voulaient l'ordre, l'abondance et la paix [...] Les Ents-femmes faisaient

10.2 Tests du Multi-query (avec RRF)

Voici les résultats des tests de Multi-query, pour chaque question, la réponse sans Multi-query puis avec, sont présentées.

Que faut-il pour publier du code source ouvert du GC ?

— R : Voici une version améliorée de votre question : Quelles sont les procédures obligatoires et les étapes recommandées pour la publication du code source ouvert par le Gouvernement du Canada (GC) ? — Pour publier du code source ouvert du Gouvernement du Canada (GC), plusieurs étapes et considérations sont requises et recommandées : **Procédures obligatoires et recommandations générales :** * Tous les codes sources doivent être publiés sous une licence de logiciel libre appropriée. Si ce n'est pas le cas, ils doivent être partagés au sein du gouvernement du Canada [Source 1, Source 2]. * Il est recommandé que les ministères publient tout le code source en tant que logiciel libre, lorsqu'ils en ont le droit. Cela s'applique aux solutions logicielles acquises en tant que logiciel libre, développées en interne par les employés du GC, ou acquises via des contrats d'approvisionnement avec des conditions de licence négociées [Source 1, Source 2]. * Si la divulgation publique n'est pas appropriée ou possible, il est recommandé de commencer par le partage interne du code source avec tous les ministères, à condition que la licence applicable l'autorise. Il faut s'assurer que la licence n'en limite pas la distribution à certains ministères utilisateurs [Source 1, Source 2]. * Le système de contrôle des versions recommandé pour le code source ouvert du GC est Git. Les ministères sont également encouragés à utiliser Git pour la gestion interne de leur code source [Source 3, Source 4]. * Il est recommandé de publier le code source le plus tôt possible dans le cycle de vie du projet pour éviter des coûts ultérieurs. Le dépôt de code source public est encouragé à être la source unique de vérité où les développeurs travaillent [Source 5]. **Étapes spécifiques pour publier le code source du GC :** 1. Demander les approbations [Source 1, Source 2]. 2. Obtenir les droits de personnaliser le code dans les contrats [Source 1, Source 2]. 3. Considérer les conséquences de sécurité [Source 1, Source 2]. 4. Choisir une licence des logiciels libres [Source 1, Source 2]. 5. Choisir un dépôt de code source [Source 1, Source 2]. 6. Ajouter des fichiers recommandés [Source 1, Source 2]. 7. Publier une ancienne application [Source 1, Source 2]. 8. Travailler dans un environnement ouvert [Source 1, Source 2].

— Multi-query : 'Que faut-il pour publier du code source ouvert du GC ?' → ['Critères de publication de code source ouvert par le Gouvernement du Canada', 'Processus de diffusion de logiciels libres au sein du GC', 'Prérequis pour rendre public du code source du gouvernement canadien']

R : Voici une version améliorée de votre question : Quelles sont les procédures obligatoires et les recommandations clés pour la publication de code source ouvert par le gouvernement du Canada (GC) ? — Pour publier du code source ouvert du gouvernement du Canada (GC), plusieurs étapes et considérations sont nécessaires : **Procédures obligatoires et exigences :**

* Tous les codes sources doivent être publiés sous une licence de logiciel libre appropriée. Si ce n'est pas le cas, ils doivent être partagés au sein du gouvernement du Canada [Source 1]. * Les ministères sont encouragés à publier tout le code source en tant que logiciel libre lorsqu'ils en ont le droit, que la solution logicielle soit acquise, développée en interne ou acquise via des contrats avec des conditions de licence négociées [Source 1]. * Lorsque la divulgation publique n'est pas appropriée ou possible, le partage interne du code source à tous les ministères est recommandé, à condition que la licence applicable l'autorise [Source 1]. * La publication du code source sous une licence de logiciel libre exige les approbations du ministère ou de l'organisme concerné [Source 2].

Étapes à suivre pour publier le code source du GC : 1. Demander les approbations [Source 1]. 2. Obtenir les droits de personnaliser le code dans les contrats [Source 1]. 3. Considérer les conséquences de sécurité [Source 1]. 4. Choisir une licence des logiciels libres [Source 1]. 5. Choisir un dépôt de code source [Source 1]. 6. Ajouter des fichiers recommandés [Source 1]. 7. Publier une ancienne application [Source 1]. 8. Travailler dans un environnement ouvert [Source 1].

Recommandations supplémentaires : * **Licence des logiciels libres :** * Si le projet fait partie d'une communauté de logiciels libres plus vaste (ex : plug-ins, modules), il est fortement recommandé d'utiliser la licence généralement employée par cette communauté [Source 5]. * Si le projet est initié par le GC et n'est pas lié à une communauté externe, le choix de la licence doit être basé sur les licences des éléments (bibliothèques et cadres tiers) utilisés et les résultats escomptés [Source 5]. * **Dépôts de code source :** Les dépôts recommandés incluent GitLab, GitHub, framagit et Bitbucket. Le GC dispose également d'un dépôt interne appelé GCcode [Source 3]. * **Système de contrôle des versions :** Git est le système de contrôle des versions recommandé pour le code source ouvert du GC, et son utilisation est également encouragée pour la gestion interne du code source par les ministères [Source 4].

Est-ce que publier ce code constitue une infraction à la loi sur la protection des renseignements personnels ?

— R : Je ne peux pas répondre à votre question. Le contexte fourni décrit des infractions liées à la protection des renseignements personnels dans le secteur privé, notamment la collecte, l'utilisation, la communication, la conservation ou la destruction de renseignements personnels en contravention à la loi, le non-signalement d'incidents de confidentialité, le non-respect des mesures de sécurité ou le fait de ne pas informer une personne concernée par une décision fondée sur un traitement automatisé [Source 3, Source 4]. Cependant, le contexte ne contient aucune information sur la publication de "code" (au sens de code source) et si cela pourrait constituer une infraction à la loi sur la protection des renseignements personnels.

— Multi-query : 'Est-ce que publier ce code constitue une infraction à la loi sur la protection des

renseignements personnels ?' → ['Légalité de la publication de code au regard de la protection des renseignements personnels', 'Violation de la législation sur les données personnelles par la diffusion de code', "Risque d'infraction à la loi sur la confidentialité des informations suite à la divulgation de code"]

R : Voici une version améliorée de votre question : La publication de code source ouvert par le gouvernement du Canada (GC) est-elle susceptible de constituer une infraction à la loi sur la protection des renseignements personnels, selon le contexte fourni ? — Le contexte fourni ne contient aucune information indiquant que la publication de code source ouvert par le gouvernement du Canada (GC) constitue en soi une infraction à la loi sur la protection des renseignements personnels. Les sources 1, 2, 4 et 5 décrivent des situations qui constituent des infractions ou des incidents de confidentialité liés aux renseignements personnels, telles que : * Recueillir, utiliser, communiquer, conserver ou détruire des renseignements personnels en contravention à la loi [Source 1]. * Ne pas déclarer un incident de confidentialité [Source 1]. * Ne pas prendre les mesures de sécurité appropriées pour protéger les renseignements personnels [Source 1]. * L'accès, l'utilisation ou la communication non autorisés par la loi d'un renseignement personnel (définition d'un incident de confidentialité) [Source 5]. La Source 3, qui détaille les étapes pour publier du code source ouvert du GC, mentionne la nécessité de "Considérer les conséquences de sécurité" [Source 3]. Bien que la sécurité soit liée à la protection des renseignements personnels, le contexte n'établit pas de lien direct entre la publication du code source et une infraction aux lois sur la protection des renseignements personnels.

Qu'est-ce qu'un renseignement personnel sensible et que faut-il faire en cas de collecte de renseignements personnels sensibles ?

— R : Voici une version améliorée de votre question : Veuillez définir ce qu'est un renseignement personnel sensible et détailler les obligations et considérations spécifiques lors de la collecte de ce type de renseignements. — Un renseignement personnel est considéré comme sensible lorsqu'il génère un haut degré d'attente raisonnable en matière de vie privée. Cette sensibilité découle de sa nature intrinsèque ou du contexte dans lequel il est utilisé ou communiqué [Source 1, Source 2]. Un exemple de renseignement sensible est celui concernant le groupe ethnique [Source 1, Source 2]. En cas de collecte de renseignements personnels (y compris sensibles), la personne qui les recueille auprès de la personne concernée doit l'informer, au moment de la collecte et par la suite sur demande : 1. Des fins pour lesquelles ces renseignements sont recueillis [Source 3, Source 4]. 2. Des moyens par lesquels les renseignements sont recueillis [Source 3, Source 4]. De plus, toute personne qui exploite une entreprise doit s'assurer que les mesures de protection des renseignements personnels collectés, utilisés, communiqués, conservés ou détruits sont raisonnables. Ces mesures doivent tenir compte, notamment, de la sensibilité des renseignements, de la finalité de leur utilisation, de leur quantité, de leur répartition et de leur support [Source 5].

— Multi-query : 'Qu'est-ce qu'un renseignement personnel sensible et que faut-il faire en cas de collecte de renseignements personnels sensibles ?' → ['Définition des données personnelles sensibles et mesures à prendre pour leur collecte', "Qu'est-ce qu'une information personnelle délicate et comment gérer sa collecte ?", 'Caractéristiques des renseignements sensibles et obligations lors de leur recueil']

R : Voici une version améliorée de votre question : Selon le contexte fourni, quelle est la définition d'un renseignement personnel sensible et quelles sont les obligations ou considérations spécifiques à prendre en compte lors de la collecte de ce type de renseignements ? — Un renseignement personnel est considéré comme sensible lorsqu'il "suscite un haut degré d'attente raisonnable en matière de vie privée, en raison de sa nature ou du contexte de son utilisation ou de sa communication" [Source 2]. Un exemple de renseignement sensible est celui concernant le groupe ethnique [Source 2]. En cas de collecte de renseignements personnels, y compris sensibles, les actions suivantes sont requises ou recommandées : * **Informer la personne concernée :** La personne qui recueille des renseignements personnels doit informer la personne concernée, lors de la collecte et sur demande, des fins auxquelles ces renseignements sont recueillis et des moyens par lesquels ils sont recueillis [Source 3]. * **Mettre en place des mesures de protection adéquates :** Il est nécessaire de prendre des mesures de protection des renseignements personnels collectés, utilisées, communiqués, conservés ou détruits. Ces mesures doivent être raisonnables et tenir compte, notamment, de la sensibilité des renseignements [Source 4]. La sensibilité du renseignement est un élément à considérer pour l'évaluation des mesures de protection [Source 5]. * **Éviter la collecte excessive :** La collecte excessive de renseignements est un exemple de risque sur la vie privée [Source 1].

Et l'EFVP ?

— R : Voici une version améliorée de votre question : Pourriez-vous expliquer ce qu'est une EFVP, pourquoi elle est réalisée, et dans quelles situations elle est requise ou recommandée ? — Une EFVP (Évaluation des Facteurs relatifs à la Vie Privée) est une démarche visant à protéger les renseignements personnels et à respecter la vie privée des personnes physiques [Source 1, Source 2]. Il s'agit d'une forme d'analyse d'impact, qui est évolutive et doit être revue tout au long du projet [Source 1, Source 2]. Elle consiste à considérer, avant de commencer un projet et pendant toute sa durée, tous les facteurs ayant un effet positif ou négatif sur la vie privée des personnes concernées [Source 1, Source 2]. **Pourquoi réaliser une EFVP ?** L'EFVP est une obligation légale dans plusieurs situations, ce qui en fait souvent une question de conformité [Source 3, Source 4]. Elle peut également être menée à titre de bonne pratique [Source 3, Source 4]. Elle permet de protéger les personnes concernées par un projet, de la collecte de leurs renseignements personnels à leur destruction, et mène à la mise en place de stratégies appropriées pour le respect de la vie privée [Source 3, Source 4]. **Quand est-elle requise ?** Il est nécessaire de réaliser une EFVP dans certaines

situations, notamment lorsqu'il s'agit de conclure ou de modifier une entente [Source 5].

— Multi-query : 'Et l'EFVP ?' → ["Qu'est-ce que l'EFVP ?", "Informations sur l'EFVP", "Signification de l'acronyme EFVP"]

  R : Voici une version améliorée de votre question : Selon le contexte fourni, quelle est la définition d'une Évaluation des Facteurs relatifs à la Vie Privée (EFVP), quel est son objectif et comment est-elle mise en œuvre ? — Une Évaluation des Facteurs relatifs à la Vie Privée (EFVP), également connue en anglais sous le nom de *privacy impact assessment (PIA)* ou *data protection impact assessment (DPIA)* [Source 4], est une démarche visant à protéger les renseignements personnels et à respecter la vie privée des personnes physiques [Source 1]. Il s'agit d'une forme d'analyse d'impact [Source 1]. **Objectifs et utilité de l'EFVP :** * Protéger les renseignements personnels et respecter la vie privée des personnes physiques [Source 1]. * Protéger les personnes concernées par un projet, de la collecte de leurs renseignements personnels à leur destruction [Source 2]. * Mener à la mise en place de stratégies appropriées pour respecter la vie privée [Source 2]. * Assurer la conformité, car l'EFVP est une obligation légale dans plusieurs situations, bien qu'elle puisse aussi être menée à titre de bonne pratique [Source 2]. **Mise en œuvre de l'EFVP :** * Elle consiste à considérer, avant de commencer un projet et tout au long de sa durée, tous les facteurs ayant un effet positif ou négatif sur la vie privée des personnes concernées [Source 1]. * L'EFVP est évolutive et doit être revue tout au long du projet [Source 1]. * Elle est typiquement documentée dans un rapport, qui peut être mis à jour au fil de son évolution [Source 4]. La Commission propose un modèle générique de rapport d'EFVP [Source 4]. * Il est recommandé de s'inspirer d'autres documents pour produire une EFVP [Source 3]. * Dans certaines situations, il est désormais nécessaire de réaliser une EFVP [Source 5].

Quelles sont les règles à adopter pour un meilleur contexte d'agent IA ?

— R : Voici une version améliorée de votre question : Quelles sont les stratégies et les meilleures pratiques recommandées pour une gestion efficace du contexte des agents d'IA afin d'optimiser leurs performances ? — Pour un meilleur contexte d'agent IA, plusieurs stratégies et pratiques sont recommandées : * **Traiter le contexte comme une ressource précieuse et finie** : C'est un principe central pour construire des agents fiables et efficaces [Source 1, Source 3]. * **Commencer avec un prompt minimal** : Il est préférable de tester un prompt minimal avec le meilleur modèle disponible pour évaluer ses performances sur la tâche. Ensuite, des instructions claires et des exemples peuvent être ajoutés pour améliorer la performance en fonction des modes de défaillance identifiés lors des tests initiaux [Source 4]. * **Utiliser des outils pour interagir avec l'environnement** : Les outils permettent aux agents d'opérer avec leur environnement et d'intégrer de nouveaux contextes supplémentaires. Il est crucial que ces outils favorisent l'efficacité [Source 4]. * **Maintenir un ensemble minimal viable d'outils** : Cela peut conduire à une maintenance plus fiable et à une meilleure gestion du contexte sur de longues interactions [Source 5]. * **Fournir

des exemples (few-shot prompting)** : C'est une bonne pratique bien connue et fortement conseillée. Cependant, il est déconseillé de surcharger le prompt avec une longue liste de cas limites pour tenter d'articuler chaque règle possible que le modèle devrait suivre. Il est plutôt recommandé de sélectionner un ensemble d'exemples pertinents [Source 5]. * **Publier le code source le plus tôt possible** : Bien que cela concerne la publication de code source ouvert par le GC, le principe de travailler dans un environnement ouvert et de publier tôt peut être transposé à la gestion du contexte en général, en évitant des coûts ultérieurs et en favorisant la collaboration [Source 5].

— Multi-query : 'Quelles sont les règles à adopter pour un meilleur contexte d'agent IA ?' → ["Recommandations pour l'optimisation du contexte d'un agent IA", 'Principes de gestion du contexte pour les agents intelligents', "Bonnes pratiques pour améliorer le contexte des agents d'intelligence artificielle"]

  R : Voici une version améliorée de votre question : Selon le contexte fourni, quelles sont les stratégies et les principes fondamentaux à adopter pour optimiser la gestion du contexte d'un agent d'IA, en particulier pour les tâches à long terme ? — Pour un meilleur contexte d'agent IA, les règles et stratégies suivantes sont à adopter : * **Curater et maintenir un ensemble optimal de jetons (informations)** : Le "context engineering" consiste à sélectionner et gérer l'ensemble optimal de jetons (informations) pendant l'inférence du modèle de langage étendu (LLM) [Source 2]. * **Traiter le contexte comme une ressource précieuse et finie** : Cette approche reste essentielle pour construire des agents fiables et efficaces [Source 3]. * **Adopter la simplicité** : L'approche "faire la chose la plus simple qui fonctionne" est conseillée pour les équipes qui développent des agents basés sur des modèles comme Claude, étant donné le rythme rapide des progrès dans le domaine [Source 4]. * **Maintenir la cohérence et le comportement orienté vers les objectifs pour les tâches à long terme** : Pour les tâches qui s'étendent sur de longues périodes (plusieurs dizaines de minutes à plusieurs heures), les agents doivent maintenir leur cohérence, leur contexte et leur comportement orienté vers les objectifs, même lorsque le nombre de jetons dépasse la fenêtre de contexte du LLM [Source 4, Source 5]. * **Gérer la pollution du contexte et la pertinence de l'information** : Même avec des fenêtres de contexte plus grandes, il est probable que la pollution du contexte et les préoccupations concernant la pertinence de l'information demeurent des défis [Source 5].

Qu'avais-tu dit par rapport aux renseignements sensibles ?

— R : Voici une version améliorée de votre question : Pourriez-vous récapituler votre définition des renseignements personnels sensibles et les points que vous avez abordés à leur sujet, en vous basant sur le contexte actuel ? — Précédemment, j'ai expliqué qu'un renseignement personnel est considéré comme sensible lorsqu'il génère un haut degré d'attente raisonnable en matière de vie privée. Cette sensibilité découle de sa nature intrinsèque ou du contexte dans lequel il est utilisé ou communiqué [Source 3, Source 4]. Un exemple de renseignement sensible est celui concernant le groupe ethnique [Source 3, Source 4]. Le contexte actuel

soulève également la question de savoir si les renseignements personnels impliqués sont sensibles lors de la communication de renseignements [Source 1, Source 2].

— Multi-query : 'Qu'avais-tu dit par rapport aux renseignements sensibles ?' → ['Mes propos antérieurs sur les données confidentielles', "Ce que j'ai communiqué concernant les informations sensibles", 'Rappel de mes directives sur les renseignements privés']

  R : Voici une version améliorée de votre question : Selon le contexte fourni, quelle est la définition d'un renseignement personnel sensible et quelles sont les considérations spécifiques mentionnées concernant sa gestion ou sa protection ? — Selon le contexte fourni, un renseignement personnel est considéré comme **sensible** lorsqu'il "suscite un haut degré d'attente raisonnable en matière de vie privée, en raison de sa nature ou du contexte de son utilisation ou de sa communication" [Source 2]. Un exemple donné de renseignement sensible est celui concernant le groupe ethnique [Source 2]. Plusieurs considérations sont mentionnées par rapport aux renseignements sensibles : * Il est important d'évaluer le degré de sensibilité des renseignements personnels impliqués [Source 2]. * La sensibilité du renseignement est un facteur à prendre en compte lors de l'évaluation des mesures de protection, y compris contractuelles, dont le renseignement bénéficierait [Source 4]. * Lors du développement de logiciels ouverts, il faut conserver les données sensibles, comme les justificatifs d'identité, en lieu sûr et séparément du code source [Source 5]. * Il faut éviter d'entreposer des clés et d'autres documents de nature délicate dans des systèmes non approuvés à cette fin [Source 5]. * L'examen des codes augmente la probabilité de détecter les vulnérabilités en matière de sécurité et réduit le risque d'engager des données sensibles [Source 5]. * Il est recommandé de tirer parti des outils et services pour automatiser la recherche de renseignements personnellement identifiables (ce qui inclut les sensibles) [Source 5]. * Il est également demandé de se questionner si les renseignements personnels impliqués sont sensibles [Source 1].